

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«РОССИЙСКИЙ ГОСУДАРСТВЕННЫЙ
ПЕДАГОГИЧЕСКИЙ УНИВЕРСИТЕТ им. А. И. ГЕРЦЕНА»

**институт информационных технологий и технологического образования
кафедра информационных технологий и электронного обучения**

Основная профессиональная образовательная программа
Направление подготовки 09.03.01 Информатика и вычислительная техника
Направленность (профиль) «Технологии разработки программного
обеспечения»
форма обучения – очная

Курсовая работа

по дисциплине «Пакеты прикладных программ для статистической
обработки и анализа данных»

Проведение корреляционного анализа при помощи прикладных программ

Обучающегося 3 курса
Суркова Андрея Анатольевича

Руководитель:
к.п.н, доцент
Гончарова С.В.

«_____» _____ 2024 г.

Санкт-Петербург

2024

ОГЛАВЛЕНИЕ

Введение.....	3
Глава 1. Теоретические основы.	4
1.1. Постановка задачи и выдвижение гипотезы.....	4
1.2. Формирование набора данных	4
1.3 Математическая модель корреляционного анализа.....	5
Глава 2. Программная реализация.....	7
2.1 Выбор способа реализации корреляционного анализа	7
2.2 Реализации на языке Python.....	7
2.3 Реализации при помощи программы KNIME	8
Заключение	9
Источники информации	10
Приложение 1	11
Приложение 2	12
Приложение 3	13
Приложение 4	14

Введение

В современном мире статистические исследования требуют обработки больших объемов данных, что является серьезной проблемой. Решением данной проблемы являются пакеты прикладных программ для статистической обработки и анализа данных, автоматизирующие и упрощающие многие задачи в этой области. Настоящая работа включает в себя проведение статистического анализа при помощи написания программы на языке Python, а также демонстрирует работу платформы для аналитики данных KNIME, что позволяет сравнить два способа проведения анализа данных и сделать выводы, в чем и заключается актуальность данной работы.

Цель работы – провести корреляционный анализ двумя способами с использованием пакетов прикладных программ, сравнить результаты и сделать выводы об эффективности методов.

Для достижения цели было необходимо решить следующие задачи:

- 1) Выдвинуть гипотезу.
- 2) Составить набор данных
- 3) Провести корреляционный анализ при помощи создания программы на языке Python.
- 4) Провести корреляционный анализ при помощи платформы KNIME.
- 5) Сделать выводы.

Практическая значимость настоящей работы:

Настоящая работа позволяет оценить эффективность и пользу современных пакетов прикладных программ для статистической обработки и анализа данных. Также, результаты и выводы, полученные при проведении корреляционного анализа, могут быть использованы в дальнейших исследованиях.

Настоящая курсовая работа включает введение, 2 части и заключение; содержит 14 страниц; 2 таблицы; 4 приложения; список источников, содержащий 5 источников.

Глава 1. Теоретические основы.

1.1. Постановка задачи и выдвижение гипотезы

Проведение корреляционного анализа является одним из способов подтверждения или опровержения гипотезы о существовании зависимости между двумя и более различными по типу величинами в наборе данных. Следовательно, для проведения корреляционного анализа необходимо выдвинуть некоторую гипотезу, после чего составить набор данных, позволяющий провести анализ. В качестве рассматриваемой гипотезы была выбрана идея о том, что показатели стоимости внутреннего валового продукта (ВВП) рассчитанного по паритету покупательной способности (ППС) за год на душу населения могут иметь корреляцию со средней продолжительностью жизни в различных странах. Такая гипотеза была выдвинута на основе предположений о том, что ВВП по ППС на душу населения является одним из макроэкономических показателей, отражающих благосостояние страны и её граждан; в то время как средняя продолжительность жизни может отражать степень удовлетворения базовых потребностей граждан. Таким образом, основной задачей данной работы является подтверждение или опровержение гипотезы о корреляции путем проведения корреляционного анализа.

1.2. Формирование набора данных

Для проведения корреляционного анализа было необходимо составить набор данных, включающий пары значений ВВП по ППС на душу населения и средней продолжительности жизни для разных стран. Прежде всего, для формирования набора данных было необходимо определиться с годом, данные за который послужат основой для проведения исследований. После краткого ознакомления с имеющимися источниками информации, было принято формировать набор данных на основе показателей 2022-го года. Такое решение было принято на основе факторов актуальности и полноты имеющихся данных. Для заполнения показателей ВВП по ППС на душу населения по странам были использованы открытые сведения Всемирного Банка [5]. В случае отсутствия необходимой информации для конкретной страны, значение ВВП по ППС на душу населения бралось из сведений Международного Валютного Фонда [4]. Если оба источника не содержали необходимой информации о рассматриваемой стране, то она исключалась из набора данных.

Данные о средней продолжительности жизни были взяты с сайта [2], ссылающегося на базу данных ЦРУ [3]. Страны, значения продолжительности жизни которых не были представлены в источнике, были удалены из набора данных.

Помимо стран с неполной статистикой, из набора данных были удалены некоторые другие страны, а именно: Нидерланды, Люксембург, Гонконг, Ирландия, Сингапур. Причиной исключения этих стран из набора данных стало то, что вышеупомянутые страны часто используются в качестве «налоговых убежищ», что искажает экономические данные и мешает многим экономическим исследованиям. Сформированный набор данных был размещен в открытый доступ в формате .xlsx (Приложение 1).

1.3 Математическая модель корреляционного анализа

Главным числовым показателем корреляционного анализа является коэффициент корреляции Пирсона, обозначаемый буквой r и рассчитывается по формуле (1).

$$r_{XY} = \frac{cov_{XY}}{\sigma_X \sigma_Y} = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sqrt{\sum (X - \bar{X})^2 \sum (Y - \bar{Y})^2}} \quad (1)$$

$$\bar{X} = \frac{1}{n} \sum_{t=1}^n X_t \quad (2)$$

$$\bar{Y} = \frac{1}{n} \sum_{t=1}^n Y_t \quad (3)$$

Один из способов трактовки числового значения коэффициента приведен в таблице 1 [1].

Таблица 1. Классификация корреляционных связей

Абсолютное значение r	Логический смысл
$ r = 0$	Корреляция отсутствует. Коэффициент корреляции случайных чисел стремится к 0
$ r < 0.19$	Очень слабая корреляция (возможно отсутствует)
$0.20 < r < 0.29$	Слабая корреляция
$0.30 \leq r \leq 0.49$	Умеренная корреляция
$0.50 \leq r \leq 0.69$	Средняя корреляция
$0.70 \leq r \leq 0.90$	Сильная корреляция
$ r > 0.90$	Очень сильная корреляция
$ r = 1$	Максимальное возможное абсолютное значение коэффициента корреляции

Также коэффициент корреляции Пирсона может иметь отрицательные значения вплоть до -1. Отрицательное значение коэффициента означает обратную зависимость рассматриваемых величин.

Также немаловажным является коэффициент детерминации R^2 , вычисляющийся по формуле 4

$$R^2 = r^2 \quad (4)$$

Коэффициент детерминации показывает долю данных в выборке, значения которых объясняются корреляцией.

Глава 2. Программная реализация.

2.1 Выбор способа реализации корреляционного анализа

Для программной реализации были выбраны два способа реализации. Первый способ реализации – при помощи программы KNIME, второй – реализация на языке программирования python. Проведение исследования двумя способами поможет удостовериться в правильности используемой математической модели и полученных результатов, а также позволит сравнить два способа проведения анализа между собой.

2.2 Реализации на языке Python

Для проведения корреляционного анализа была разработана программа на языке программирования Python. Программа содержит идентификаторы, описанные в таблице в приложении 2.

Структура матрицы данных v , используемой в программе, представлена в таблице 2

Таблица 2. Структура матрицы данных

Страна1	x_1	y_1	x_1^2	y_1^2	$x_1 * y_1$
...	...	...	...	...	...
Страна185	x_{185}	y_{185}	x_{185}^2	y_{185}^2	$x_{185} * y_{185}$

Где x – это средняя продолжительность жизни, y – ВВП по ППС на душу населения в долларах США.

В результате работы программы были получены значение коэффициентов корреляции и детерминации.

Коэффициент корреляции равняется 0.721. Согласно таблице 1, это означает тесную связь между значениями ВВП по ППС на душу населения и средней продолжительности жизни в странах.

Коэффициент детерминации равняется 0.52, из чего можно сделать вывод о том, что 52% различий продолжительности жизни в странах объясняется разностью в показателе ВВП по ППС на душу населения, в то время как остальные 48% объясняются другими не учитываемыми факторами.

Из полученных результатов следует, что связь есть, но для построения точных прогнозов может потребоваться анализ других факторов или применение нелинейных методов.

Разработанная программа была выложена на сервис GitHub, и может быть найдена по ссылке в приложении 3

2.3 Реализации при помощи программы KNIME

KNIME это платформа для аналитики данных, значительно упрощающая проведение статистических исследований. Для работы с KNIME, созданный ранее набор данных был преобразован в файл формата .xlsx (приложение 1), после чего был загружен в программу. После создания и настройки модели, рассчитывающей коэффициент корреляции установленных для параметров, были получены результаты, совпадающие с результатами, полученными при использовании программы на языке Python. Это говорит о правильности используемой математической модели.

Стоит отметить, что использование платформы KNIME действительно значительно упрощает проведение анализа и не требует знания математической модели. Использование пакетов прикладных программ экономит время и делает работу проще, значительно снижая вероятность совершения ошибки.

Ссылка на архив программы KNIME с построенной моделью размещена в приложении 4

Заключение

В ходе выполнения курсовой работы был собран набор данных и разработана программа на языке Python, позволяющая провести корреляционный анализ с заданным набором данных. Результаты работы программы были проанализированы и сравнены с результатами аналогичного анализа, проведенного при помощи платформы KNIME. Была оценена работа платформы и сделаны выводы. Программа (приложение 3) и архив с моделью платформы KNIME (приложение 4) были выложены в открытый доступ.

Информационные источники

1. Вятский государственный университет. Корреляционный анализ [Электронный ресурс] – https://e.vyatsu.ru/pluginfile.php/462616/mod_resource/content/3/Теоретический%20материал_корреляционный%20анализ.pdf свободный. – Яз. рус. (дата обращения: 14.12.2024).
2. Иванова Е. Рейтинг стран по продолжительности жизни [Электронный ресурс] – <https://basetop.ru/rejting-stran-po-prodolzhitelnosti-zhizni/> свободный. – Яз. рус. (дата обращения: 14.12.2024).
3. Central Intelligence Agency. Life expectancy at birth [Электронный ресурс] – режим доступа <https://www.cia.gov/the-world-factbook/about/archives/2022/field/life-expectancy-at-birth/country-comparison>, по особым условиям в локальной сети владельца. – Яз. англ. (дата обращения: 14.12.2024).
4. International Monetary Fund. GDP based on purchasing-power-parity (PPP) per capita [Электронный ресурс] – <https://www.imf.org/en/Publications/WEO/weo-database/2023/April/weo-report?c=512,914,612,171,614,311,213,911,314,193,122,912,313,419,513,316,913,124,339,638,514,218,963,616,223,516,918,748,618,624,522,622,156,626,628,228,924,233,632,636,634,238,662,960,423,935,128,611,321,243,248,469,253,642,643,939,734,644,819,172,132,646,648,915,134,652,174,328,258,656,654,336,263,268,532,944,176,534,536,429,433,178,436,136,343,158,439,916,664,826,542,967,443,917,544,941,446,666,668,672,946,137,546,674,676,548,556,678,181,867,682,684,273,868,921,948,943,686,688,518,728,836,558,138,196,278,692,694,962,142,449,564,565,283,853,288,293,566,964,182,359,453,968,922,714,862,135,716,456,722,942,718,724,576,936,961,813,726,199,733,184,524,361,362,364,732,366,144,146,463,528,923,738,578,537,742,866,369,744,186,925,869,746,926,466,112,111,298,927,846,299,582,487,474,754,698,&s=PPPPC,&sy=2021&ey=2022&ssm=0&scsm=0&sc=0&ssd=1&ssc=0&sic=1&sort=country&ds=,&br=1> свободный. – Яз. англ. (дата обращения: 14.12.2024).
5. World Bank Group. GDP per capita [Электронный ресурс] – режим доступа https://data.worldbank.org/indicator/NY.GDP.PCAP.PP.CD?end=2022&most_recent_value_desc=true, свободный. – Яз. англ. (дата обращения: 14.12.2024).

Приложение 1

Набор данных в формате .xlsx:

<https://disk.yandex.ru/i/elj0hXneA5ZKwg>



Приложение 2

Наименование	Тип	Логический смысл
sx	double	Сумма по столбцу x
sy		Сумма по столбцу y
sxx		Сумма квадратов столбца x
syu		Сумма столбца y
sxy		Сумма произведений столбцов x и y
mx		Среднее арифметическое для столбца x
my		Среднее арифметическое для столбца y
mxx		Среднее арифметическое квадратов столбца x
myu		Среднее арифметическое квадратов столбца y
mxy		Среднее арифметическое произведений столбцов x и y
skox		Среднеквадратичное отклонение по столбцу x
skoy		Среднеквадратичное отклонение по столбцу y
r		Коэффициент корреляции
n	int	Количество рассматриваемых данных
v	list	Матрица данных
i	Ссылочный	Строка матрицы данных

Приложение 3

Код программы:

<https://github.com/A-Surkov-2004/Course3Py>



Приложение 4

Архив модели KNIME:

<https://disk.yandex.ru/d/7ZrPWc92QdfWlw>

